COHÉRENCE BAYÉSIENNE ENTRE CONNAISSANCE A PRIORI ET DONNÉES OBSERVÉES

BAYESIAN COHERENCE BETWEEN PRIOR KNOWLEDGE AND OBSERVED DATA

N. Bousquet et G. Celeux
Équipe SELECT, INRIA Futurs
Bât. 425, Université Paris XI
91405 Orsay, France
nicolas.bousquet@math.u-psud.fr
gilles.celeux@inria.fr

F. Billy et E. Remy
EDF R.&D.
6 quai Watier
78401 Chatou, France
francois.billy@edf.fr
emmanuel.remy@edf.fr

Résumé
Cet article propose un critère statistique pour détecter les conflits entre expertise et densité de données observées (ou retours d'expérience), dans des contextes où l'apport d'information a priori est indispensable pour obtenir des précisions sur des quantités de la fiabilité. La construction de ce critère est étudiée dans un contexte général, mais cette démarche étant issue de problèmes concrets rencontrés par EDF, elle est illustrée par l'analyse des lois exponentielles et de Weibull. De plus, l'utilisation de ce critère comme outil de calibration est évoquée en conclusion.

Summary
A criterion allowing to detect the potential discrepancy between subjective prior distributions and data, when Bayesian inference is used, is proposed. Elicitation of this coherence criterion is studied in a general context. However, this study being based on concrete problems encountered by EDF, developments are given for exponential and Weibull models. Finally, using the coherence criterion as a tool for calibrating prior knowledge is discussed.

Contexte

Dans de nombreuses études de fiabilité, la durée de vie X d'un système industriel est représentée par un modèle paramétrique $\mathscr{M}(\theta)$ de densité de probabilité $f(x|\theta)$. L'estimation du paramètre $\theta \in \Theta \subset \mathbb{R}^p$ est souvent problématique, de par la faible taille et le caractère fortement censuré des échantillons $\mathbf{X_n} = (X_1, \ldots, X_n)$ de temps de défaillance disponibles (retours d'expérience). Dans de tels cas, les techniques d'inférence bayésienne sont à privilégier quand une information a priori est disponible (cf. [23]). Bien souvent, elle émane d'experts industriels et reflète une connaissance subjective du comportement du système.

Cependant, l'inférence bayésienne peut se révéler dangereuse lorsque la vraisemblance des données observées $\mathscr{L}(\mathbf{X_n}; \theta)$ et la connaissance *a priori* présentent un désaccord important. Selon les cas, l'un ou l'autre fournit une mauvaise information et il est impératif de pouvoir détecter un tel conflit. Notons cependant que dans la stricte acceptation du paradigme bayésien, la modélisation *a priori* et la vraisemblance constituent le modèle complet de prise de décision et il peut sembler sans objet de chercher à déterminer des degrés de divergence entre ces deux grandeurs. Nous insistons donc sur le caractère concret de cette étude. Nous présentons dans les Tableaux 1 et 2 l'exemple d'un tel décalage entre ces deux formes de connaissance.

Le tableau 1 présente des données de durée de vie censurées à droite pour un composant du circuit secondaire d'une centrale nucléaire. L'unité est le mois. Ces données étant supposées suivre le modèle de Weibull de densité

$$f(x|\eta,\beta) = \frac{\beta}{\eta}\left(\frac{x}{\eta}\right)^{\beta-1} \exp\left\{-\left(\frac{x}{\eta}\right)^{\beta}\right\} \mathbb{1}_{[0,+\infty[}(x),$$

l'estimation fréquentiste de la durée de vie moyenne est $\hat{X} = \hat{\eta}\Gamma(1+1/\hat{\beta}) = 128.5$ mois, où $(\hat{\eta}, \hat{\beta}) = (140.8, 4.51)$ sont les estimations du maximum de la vraisemblance (EMV). Le tableau 2 indique quelques caractéristiques de cette même durée de vie perçue par deux experts indépendants $\mathscr{E}_1$ et $\mathscr{E}_2$.

Temps de défaillance	134.9, 152.1, 133.7, 114.8, 110.0, 129.0, 78.7, 72.8, 132.2, 91.8
Temps de censure à droite	70.0, 159.5, 98.5, 167.2, 66.8, 95.3, 80.9, 83.2

Tableau 1. Données de durées de vie $\mathbf{X_n}$ de composant nucléaire (mois).

	Intervalle de confiance (5%,95%)	Valeur médiane
Expert $\mathscr{E}_1$	(200,300)	250
Expert $\mathscr{E}_2$	(100,500)	250

Tableau 2. Avis d'expert sur la durée de vie X (mois).

Ces deux experts sont très optimistes quant à la durée de vie de ce composant, puisqu'ils se situent à droite des données $\mathbf{X_n}$ et de $\hat{X}$. En particulier, l'opinion de l'expert $\mathscr{E}_1$ est à la fois très précise et très décalée. Dans ce cas particulier, les points suivants permettent d'expliquer le désaccord :

- *le décalage technique* (ou temporel) ; tandis que les données reflètent un passé plus ou moins proche, les expertises s'établissent en fonction d'un renouvellement de connaissances techniques et conceptuelles. L'obsolescence éventuelle de certaines données influentes accentue encore ce décalage.

- *l'hétérogénéité des expertises* ; les experts $\mathscr{E}_1$ et $\mathscr{E}_2$ ne sont pas interrogés dans les mêmes conditions. En effet, l'avis $\mathscr{E}_1$ reflète la connaissance très précise d'un exploitant sur une tranche nucléaire donnée, tandis que l'avis $\mathscr{E}_2$ émane d'un constructeur. Celui-ci tient compte des conditions d'exploitation pour délivrer son expertise, et cette dernière, de façon naturelle, est plus modérée que l'avis $\mathscr{E}_1$ mais aussi moins précise, donc moins intéressante d'un point de vue fiabiliste.

De façon très générale, d'autres décalages surviennent dans les cas suivants :

1. une expertise correcte face à des données hétérogènes (mélange de populations) ou d'obtention erronée ;
2. une expertise fausse face à des données correctes.

La détection d'un a priori trop éloigné ou en accord avec des données considérées comme fiables permet donc de donner une note critique à l'expertise (et de la calibrer). Réciproquement, si l'expertise émane d'un large consensus, la détection éventuelle d'un conflit fournit une mesure de la validité des données.

Motivations

Dans une première partie, nous analysons quelques approches précédemment proposées, notamment celle de Dumon, Guérin et Usureau ([13], [25]). Bien que dépourvue de justification statistique, celle-ci a le mérite de présenter une vue claire et intuitive du problème. Nous établissons alors un critère simple (1) et statistiquement viable pour définir la cohérence d'une modélisation a priori vis-à-vis de la connaissance objective disponible, pour n'importe quel modèle $\mathscr{M}(\theta)$.

Dans un second temps, nous présentons quelques aspects techniques inhérents à l'utilisation de ce critère. En particulier, il est nécessaire de pouvoir définir une densité *a priori* minimalement informative pour le problème, qui soit cohérente avec les données. Pour cela, nous proposons une approche générale par l'utilisation d'*a priori a posteriori* (*posterior priors*).

Enfin, nous utiliserons des données exponentielles simulées et les données de Weibull du tableau 1 pour illustrer le comportement de ce critère. L'utilisation de celui-ci comme outil de calibration d'un *a priori* subjectif sera évoqué en conclusion.

Une définition statistique de la cohérence *a priori* - données

1. Travaux précédents

De façon suprenante, il y a très peu de travaux en la matière en fiabilité bayésienne, bien qu'elle constitue un préliminaire important à toute prise en compte des résultats d'inférence - en particulier lorsqu'une connaissance subjective est utilisée. Des auteurs comme O'Hagan ([16], [17], [18], [19], [20]) et Angers [1] se sont surtout attachés à définir des modélisations *a priori* dont l'influence *a posteriori* diminue lorsque l'écart augmente entre données et expertise, et des procédures de rejet de données atypiques. Dans le domaine de la fiabilité industrielle, [14] propose l'utilisation d'un test de Fisher entre des mesures d'incertitudes *a priori* et empiriques.

Plus particulièrement, l'approche de Dumon, Guérin et Usureau ([13], [25]) propose une vision très intuitive du problème (en particulier dans le cas exponentiel où θ est assimilable à une durée de vie). Ils définissent un produit de convolution

$$\delta_{\pi,\mathscr{L}} \quad = \quad \pi \otimes \mathscr{L}(\mathbf{X_n}, .)$$

dont la valeur croît avec la similarité de forme de ces fonctions de θ. En translatant π le long de l'axe Θ, ils calculent une valeur maximale $\max_\pi \delta_{\pi,\mathscr{L}}$ de ce produit de convolution (si ces deux fonctions de θ sont unimodales, cette maximisation est réalisée en l'égalité des modes). Ils en déduisent alors un pourcentage de cohérence

$$\frac{\delta_{\pi,\mathscr{L}}}{\max_\pi \delta_{\pi,\mathscr{L}}}.$$

Nos critiques portent principalement sur les points suivants :

1. Ce critère n'a pas de justification statistique générale puisqu'il considère implicitement la vraisemblance $\theta \mapsto \mathscr{L}(\mathbf{X_n}, \theta)$ comme une densité de probabilité sur θ, ce qui est abusif.
2. Il ne permet pas de définir de façon objective une limite de cohérence, c'est-à-dire une valeur limite telle que l'on puisse refuser une expertise, si les données sont supposées correctes.

Après avoir introduit quelques notations nécessaires à la formalisation du problème, nous nous inspirons de cette approche pour proposer une démarche viable statistiquement, qui réponde également à ce deuxième souhait.

2. Notations

Soit π une mesure sur Θ. Si π est une densité, on notera P_π la distribution de probabilité bayésienne qui lui est associée.

Si $t(\theta)$ est une fonction d'intérêt de θ, on note $P_\theta(t(\theta) \in A)$ la probabilité fréquentiste (θ étant fixé) associée à un évènement A aléatoire et $P_\pi(t(\theta) \in A)$ la probabilité bayésienne (A étant fixé).

Par ailleurs, on note

$$\pi(\theta|\mathbf{X_n}) \quad = \quad \frac{\pi(\theta)\mathscr{L}(\mathbf{X_n},\theta)}{\int_\Theta \pi(\theta)\mathscr{L}(\mathbf{X_n},\theta)\,d\theta}$$

la densité *a posteriori* de θ sachant les données $\mathbf{X_n}$.

Enfin, on notera toujours S l'espace des données (en général, $S =]0,\infty[$ pour des problèmes de fiabilité).

3. Formalisation du critère

Supposons qu'il soit possible de construire pour $\mathscr{M}(\theta)$ une mesure *a priori* π^J telle qu'il existe $i > 0$,

$$P_\theta\{\theta \leq \theta_n(\alpha)\} = P_{\pi^J}\{\theta \leq \theta_n(\alpha)|\mathbf{X_n}\} + O(n^{-i/2})$$

où $\theta_n(\alpha)$ est le quantile d'ordre α *a posteriori* (i.e. $P_{\pi^J}(\theta \leq \theta_n(\alpha)|\mathbf{X_n}) = \alpha$). Ainsi $\pi^J(.|\mathbf{X_n})$ n'apporte pas plus d'information que la vraisemblance des données, à $n^{-i/2}$ près. Ainsi, π^J est qualifiée de non informative.

De telles mesures *a priori* π^J existent et possédent donc une certaine validité fréquentiste en termes de recouvrement *a posteriori*. Elles ont été étudiées en particulier par [11] et [12], sous le terme de *coverage matching priors*. Elles regroupent en particulier la mesure de Jeffreys

$$\pi^J(\theta) \quad \propto \quad \sqrt{\det I(\theta)}$$

où $I(\theta)$ est la matrice de Fisher de $\mathscr{M}(\theta)$, et les *reference priors* de Berger et Bernardo [3]. Quand la dimension p de Θ vaut 1, ce choix est restreint à la mesure de Jeffreys. On aboutit alors à l'hypothèse suivante, en sélectionnant le π^J avec la meilleure propriété de recouvrement.

Hypothèse 1 : pour le modèle $\mathscr{M}(\theta)$, on peut créer une densité $\pi^J(\theta|\mathbf{X_n})$ qui modélise un expert "parfaitement" en accord avec les données.

Sous cette hypothèse, $\pi^J(\theta|\mathbf{X_n})$ constitue une référence pour tout *a priori* $\pi(\theta)$ dont on souhaite évaluer la proximité avec les données. Ces deux distributions de probabilité sur Θ peuvent être comparés par la divergence de Kullback-Leibler

$$KL\left\{\pi^J(.|\mathbf{X_n}) \,||\, \pi\right\} \quad = \quad \int_\Theta \pi^J(.|\mathbf{X_n}) \log \frac{\pi^J(.|\mathbf{X_n})}{\pi(\theta)}\,d\theta$$

qui permet de mesurer le *regret en termes d'information de Shannon* dû au choix de π quand le meilleur choix pour le problème était $\pi^J(.|\mathbf{X_n})$ (voir [10]). Quand π s'éloigne des données, alors $KL\{\pi^J(.|\mathbf{X_n}) \,||\, \pi\}$ augmente. Nécessairement, une valeur limite de cette quantité doit être fixée pour obtenir une règle de rejet.

Puisque par définition une mesure non informative ne privilégie aucune partie de Θ, il est raisonnable de la considérer *de facto* comme cohérente avec les données. En outre, l'écart entre π^J et $\pi^J(.|\mathbf{X_n})$ est une mesure de l'information apportée par les données. Cette distance constitue un seuil que seules franchissent les densités trop éloignées des données ou trop informatives. Ainsi, la frontière de cohérence est atteinte quand $\pi = \pi^J$. On aboutit alors à la définition suivante d'une règle de cohérence normalisée.

DÉFINITION 1. *Sachant π^J, on définit le critère de cohérence par*

$$\mathscr{C}oh(\pi;\mathbf{X_n}) \quad = \quad \frac{KL\left(\pi^J(.|\mathbf{X_n}) \,||\, \pi\right)}{KL\left(\pi^J(.|\mathbf{X_n}) \,||\, \pi^J\right)} \qquad (1)$$

et π est considéré comme cohérent avec les données si $\mathscr{C}oh(\pi;\mathbf{X_n}) \leq 1$.

4. Difficultés

L'utilisation du critère (1) tel quel est cependant réservé aux cas où π^J est *propre* (π^J est une densité de probabilité), i.e. si

$$\int_\Theta \pi^J(\theta)\,d\theta \quad = \quad 1.$$

Cette condition est réalisée dans les deux cas suivants :

1. le modèle $\mathscr{M}(\theta)$ est discret ;
2. l'espace Θ est borné.

Notons que le second cas est courant dans les problèmes industriels : les contraintes techniques ou les impossibilités physiques sont souvent mises à contribution pour établir des domaines *a priori* bornés pour les paramètres. Dans la suite de ce travail, nous abordons le cadre plus délicat où $\mathscr{M}(\theta)$ est continu et où Θ n'est pas borné.

En effet, il est alors nécessaire de définir une distribution de densité de probabilité π^{MIA} qui "remplace" π^J dans l'expression (1), et qui est alors perçue comme la modélisation de l'expertise *la plus faiblement informative pour le problème, qui soit cohérente avec les données*. C'est l'enjeu de la partie suivante (le terme MIA renvoie à *minimally informative prior, in agreement with data*, voir [7]).

Choix d'une densité de référence minimalement informative

La construction d'une densité reflétant le minimum d'information acceptable pour un problème donné est une gageure de la statistique bayésienne objective. Maximum d'entropie sous contraintes, densité localement uniformes sur le domaine de la vraisemblance... De nombreuses procédures peuvent tenter de fournir des candidats π^{MIA} en utilisant au minimum les données. Dans cette partie, on introduit deux idées principales : l'élicitation de candidats dits *posterior priors* et la sélection du candidat le moins informatif. Les modèles exponentiel et de Weibull illustreront cette approche. Par ailleurs, une définition alternative de (1) est proposée lorsqu'aucun candidat π^{MIA} ne peut facilement être construit ou manié.

1. Construction de *posterior priors*

Une façon simple de construire des candidats π^{MIA} est de réajuster π^J en le conditionnant vis-à-vis d'un *minimal training sample* (MTS) $X(l)$, soit un échantillon de taille minimale pour que $\pi^J(.|X(l))$ soit propre. Berger, Perrichi, Pérez et Varshavsky ([4], [5], [6], [21], [22]) ont formalisé cette approche, popularisée sous le nom d'élicitation d'*a priori a posteriori* (*posterior prior*), dans le contexte de la sélection de modèle. On peut la résumer de la façon suivante.

1. On choisit une mesure g_i sur l'espace $\chi = S^m$ où m est la taille d'un MTS $X(l)$ du problème ;
2. on propose le candidat

$$\pi_i^{MIA}(\theta) \quad \propto \quad \int_\chi \pi^J(\theta|X(l))\, g_i(dX(l)).$$

Le choix d'une mesure g_i neutre est, en sélection de modèle, très généralement celui d'une loi marginale

$$g_i(X(l)) \quad \propto \quad \int_\Theta \pi_i^N(\theta) f(X(l)|\theta)\, d\theta$$

où π_i^N est une mesure non informative. On peut aussi supposer l'espace χ borné (sans doute plus facilement que l'espace paramétrique Θ, car il s'agit d'un espace de grandeurs observables ; dans des problèmes de durée de vie, c'est un espace-produit des temps de fonctionnement) et ainsi choisir g_i comme une loi uniforme. Dans notre cadre d'étude, nous cherchons à créer des candidats π^{MIA} centrés sur les données (tout en les utilisant au minimum).

De façon générale, un candidat qui fait sens est le *posterior prior* empirique et arithmétique

$$\pi_{AR}^{MIA}(\theta) \quad = \quad \frac{1}{L}\sum_{i=1}^{L} \pi^J(\theta|X(l_i))$$

où $L = \binom{r}{m}$, avec r le nombre de données parmi n pouvant former un MTS (réduit par facilité aux données non censurées), les MTS $X(l_i)$ étant piochés dans $\mathbf{X_n}$. On aboutit également à une définition arithmétique du critère de cohérence :

$$\mathscr{C}oh_{AR}(\pi;\mathbf{X_n}) = \frac{1}{L}\sum_{i=1}^{L} \frac{KL\left\{\pi^J(.|X(l_i),\mathbf{X_n}) \;||\; \pi\right\}}{KL\left\{\pi^J(.|X(l_i),\mathbf{X_n}) \;||\; \pi^J(.|X(l_i))\right\}}. \quad (2)$$

Sa version *"leave-one-MTS-out"*

$$\widetilde{\mathscr{C}oh}_{AR}(\pi;\mathbf{X_n}) = \frac{1}{L}\sum_{i=1}^{L} \frac{KL\left\{\pi^J(.|\mathbf{X_n}) \;||\; \pi\right\}}{KL\left\{\pi^J(.|\mathbf{X_n}) \;||\; \pi^J(.|X(l_i))\right\}}$$

qui n'utilise pas deux fois les données, s'est révélée plus sensible à la présence de données atypiques, dans le cas d'un n petit et d'une censure importante.

Le candidat π_{AR}^{MIA} est ainsi explicite pour les modèles exponentiel et de Weibull (voir [7]). Par ailleurs, on peut facilement produire un autre candidat pour le modèle exponentiel de densité

$$f(x|\lambda) \quad = \quad \lambda \exp(-\lambda x)\, \mathbb{1}_{[0,+\infty[}(x).$$

Pour ce modèle, un MTS est composé d'une donnée non censurée ($m = 1$), et une proposition raisonnable est d'utiliser une mesure g_i centrée en la statistique exhaustive $\hat{X}_n$ des données (le maximum de vraisemblance dans le cas censuré, la moyenne sinon). En particulier, si l'on choisit pour g_i une mesure de Dirac en $\hat{X}_n$, on obtient le candidat conjugué

$$\pi_C^{MIA}(\lambda) \quad = \quad \hat{X}_n \exp\left(-\hat{X}_n\lambda\right).$$

2. Sélection entre candidats

Notons $\Pi^{MIA} = \{\pi_i^{MIA}, i \in I\} \subset \Pi^I$ un ensemble de candidats et $\pi_i^{MIA} \in \Pi^{MIA}$ un candidat choisi d'après les choix de π^J et g_i. On cherche à déterminer π^{MIA} la densité de la loi *a priori* la moins informative parmi les éléments de Π^{MIA}.

Nous privilégions pour cela la vision suivante : $\pi^{MIA}(.|\mathbf{Y_n})$ doit être la densité la plus proche de $\pi^J(.|\mathbf{Y_n})$ lorsque $\mathbf{Y_n}$ sont des variables aléatoires i.i.d suivant la densité marginale $m_i(x) = \int_\Theta \pi^{MIA}(\theta)p(x|\theta)\; d\theta$, définies sur $S^n = S \times \ldots \times S$ avec n assez grand. On définit le *regret prédictif a posteriori* par

$$\mathscr{R}_n(i) \quad = \quad \int_{S^n} KL\left\{\pi^J(.|\mathbf{Y_n}) \;||\; \pi_i^{MIA}(.|\mathbf{Y_n})\right\}\; m_i(\mathbf{Y_n})\, d\mathbf{Y_n}.$$

Pour des raisons de normalité asymptotique *a posteriori*, sous des conditions de régularité classiques, $\mathscr{R}_n(i) \to 0$ quand $n \to \infty$ (cf. [9]). On propose alors le critère asymptotique

$$\pi^{MIA} \quad = \quad \arg\min_{i\in I} \lim_{n\to\infty} \sum_{j\in I, j\neq i} \frac{\mathscr{R}_n(i)}{\mathscr{R}_n(j)}. \qquad (C_1)$$

REMARQUE 1. *On peut se contenter dans une étude appliquée de sélectionner (pour une taille n fixée ou des données particulières)*

$$\pi^{MIA} \quad = \quad \arg\min_{i\in I} \mathscr{R}_n(i),$$

$$\pi^{MIA} \quad = \quad \arg\min_{i\in I} KL\left\{\pi^J(.|\mathbf{X_n}) \;||\; \pi_i^{MIA}(.|\mathbf{X_n})\right\}.$$

Application au modèle exponentiel

Avec $\pi^J(\lambda) \propto \lambda^{-1}$ (loi de Jeffreys), on obtient

$$\pi^J(\lambda|\mathbf{X_n}) \quad = \quad \mathscr{G}\left(r, \sum_{i=1}^{n} X_i\right)$$

où r est le nombre de données non censurées parmi n et $\mathscr{G}(a,b)$ désigne la loi gamma de moyenne a/b et de variance a/b^2. Parmi un certain nombre de candidats π_i^{MIA}, le critère (C_1) sélectionne opportunément π_C^{MIA} comme le moins informatif (cf. [7]). Le critère (1) est alors explicite.

On simule selon $\mathscr{E}(\lambda_0 = 150^{-1})$ $n = 10$ données $\mathscr{E} = (142.76, 142.99, 470.3, 419.09, 185.20, 84.41, 8.13, 27.15, 573.17, 17.12)$. Le maximum de vraisemblance $\hat{\lambda} = 207^{-1}$ sous-estime largement la valeur réelle. On propose alors d'utiliser un *a priori* conjugué

$$\pi(\lambda) \quad = \quad \mathscr{G}(a, aX_e)$$

où X_e est une valeur centrale proposée par un expert et a est assimilable à une taille d'échantillon fictif de moyenne X_e. Ainsi a est un paramètre calibré par un analyste bayésien pour modéliser l'incertitude de l'expert. Plus a est grand, plus $\mathrm{Var}[\lambda]$ diminue. Le choix qui minimise le critère de cohérence (1) est donc $a = n = 10$, $X_e = \hat{X} = 207$.

On représente sur les figures 1 et 2 l'évolution du critère $\mathscr{C}oh(\pi; \mathbf{X_n})$ en fonction de X_e (de part et d'autre de $\hat{X}$) et de a. Celui-ci adopte un comportement à la fois intuitif et rassurant :

1. la valeur de $\mathscr{C}oh(\pi; \mathbf{X_n})$ décroît avec la diminution du biais $|X_e - \bar{X}|$, et lorsque a s'approche de sa valeur optimale n ; l'intervalle de cohérence se restreint cependant lorsqu'on augmente la confiance en l'expert (lorsque a augmente).

2. Même un avis d'expert très peu biaisé par rapport au données $(X_e \simeq \hat{X})$ peut être rejeté par la règle de cohérence (cf. Fig.2), s'il modélise une incertitude trop faible $(a \gg n)$ vis-à-vis de l'incertitude fréquentiste. En d'autres termes, le critère (1) permet à la fois d'écarter des *a priori* très biaisés, même avec une incertitude étendue, et des *a priori* peu biaisés mais déraisonnablement privilégiés.

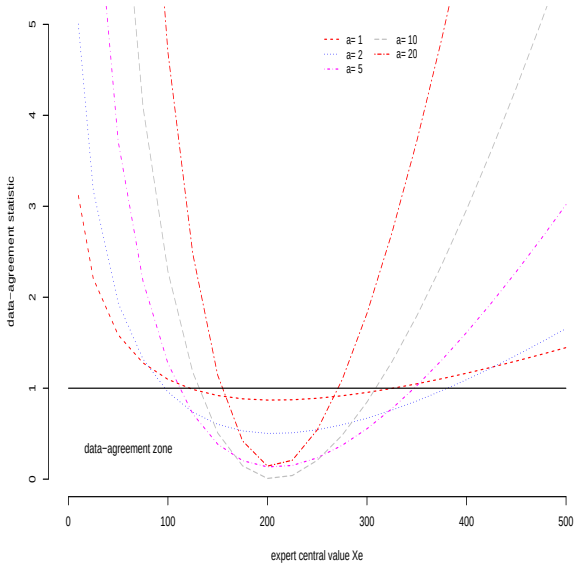


FIG. 1 – Évolutions de $\mathscr{C}oh(\pi; \mathbf{X_n})$ en fonction de X_e autour de $\hat{X} = 207$, pour des choix de a variés.

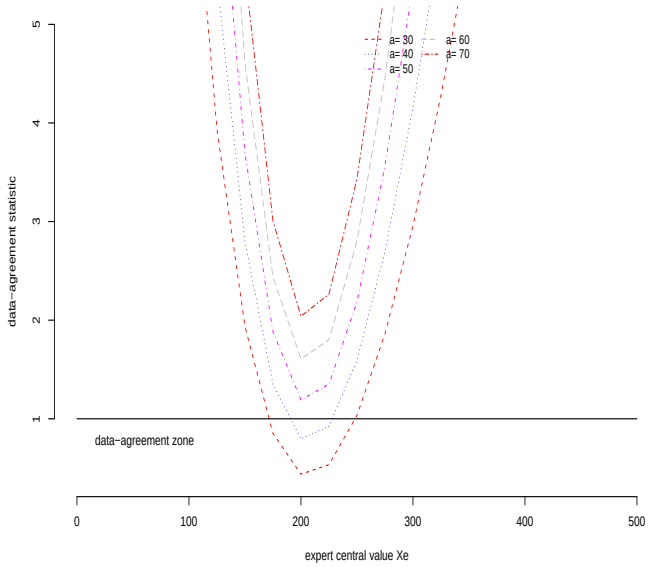


FIG. 2 – Évolutions de $\mathscr{C}oh(\pi; \mathbf{X_n})$ en fonction de X_e autour de $\hat{X} = 207$, pour des choix de a variés.

Application au modèle de Weibull

Nous reprenons ici les données et les expertises des tableaux 1 et 2. L'expertise s'exerce sur la grandeur observable X et non sur le couple (η,β). Cependant, il est usuel en fiabilité de privilégier des valeurs de β dans $D_\beta = [1,5]$ lorsqu'un vieillissement est avéré, et des valeurs > 5 sont considérées comme très peu probables (cf. [15] et [2]).

L'information sur β sous-jacente à l'avis de l'expert étant par ailleurs beaucoup moins perceptible que celle sur le paramètre d'échelle η, on propose d'utiliser la modélisation suivante :

$$\begin{aligned} \pi(\beta|\beta_0,\alpha_\beta) &= \mathscr{G}(\alpha_\beta,\alpha_\beta\beta_0^{-1}), \\ \pi(\eta|t,\alpha_\eta) &= \mathscr{G}\left(\alpha_\eta,\alpha_\eta\frac{\Gamma(1+1/\tilde{\beta})}{t}\right) \end{aligned}$$

où $\tilde{\beta} = 3$ (le milieu de D_β), et α_η, t et l'écart-type σ_η prennent les valeurs du tableau 3. L'espérance *a priori* $\beta_0 \in D_\beta$ et l'écart-type $\sigma_\beta = \beta_0/\sqrt{\alpha_\beta}$ seront des paramètres variables de l'étude. Ce faisant, on transforme l'information sur X en une information sur η. Les deux paramètres (η,β) sont supposés indépendants par simplicité.

	Intervalle (5%,95%)	Médiane	t	α_η	σ_η
$\mathscr{E}_1$	(224,336)	280	252	60	36.4
$\mathscr{E}_2$	(112,560)	280	269	4.5	142

Tableau 3. Avis d'expert transformés sur η et calibration de $\pi(\eta)$.

Un MTS est composé de deux données $X_i \neq X_j > 1$ (cf. [24]). D'après [7], en choisissant $\pi^J(\eta,\beta)$ comme la mesure de Jeffreys, le candidat le plus naturel est $\pi^{MIA}_{AR}(\eta,\beta) = L^{-1}\sum_{i=1}^{L}\pi^J(\eta,\beta|X_i,X_j)$. En notant $\mu = \lambda^\beta$ et $\pi^{ij} = \pi^J(\mu,\beta|X_i,X_j)$, on obtient

$$\begin{aligned} \pi^{ij}(\mu|\beta) &= \mathscr{G}\left(2, X_i^\beta + X_j^\beta\right), \\ \pi^{ij}(\beta) &= \frac{(X_iX_j)^{\beta-2}}{2|\log X_i/X_j|\left(X_i^\beta + X_j^\beta\right)^2}. \end{aligned}$$

En l'absence d'autres candidats π^{MIA} explicites, nous avons comparé l'évolution des critères de cohérence (1) et (2), lorsque l'on fait varier β_0 et σ_β. Un exemple d'évolution de ces deux statistiques est présenté sur la figure 3, pour $\sigma_\beta = 1.5$. $L = 30$ MTS ont été utilisés pour calculer les deux critères. D'une façon générale, la forme arithmétique (2) du critère varie de façon plus régulière.

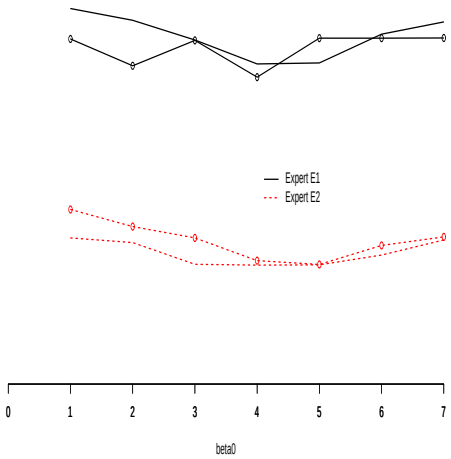


FIG.3 - Variations des critères (1) [—o—] et (2) [—-] pour les modélisations des avis $\mathscr{E}_1$ et $\mathscr{E}_2$. L'échelle est ôtée pour la lisibilité.

Nous présentons alors sur les figures 4 et 5 l'évolution du critère arithmétique $\mathscr{C}oh_{AR}(\pi;\mathbf{X_n})$ pour chacune des deux expertises, en fonction de l'évolution de β_0 et σ_β. La frontière de cohérence n'est jamais atteinte pour l'*a priori* $\mathscr{E}_1$ tandis que pour un choix de (β_0,σ_β) relativement large, l'expertise $\mathscr{E}_2$ est modélisable de façon à être en accord avec les données.

L'incohérence ainsi détectée dans le cas $\mathscr{E}_1$ conduit à la réflexion suivante. En absence d'une réelle information sur β, qui n'est pas évidente à obtenir, on doit pouvoir privilégier des valeurs de faible vieillissement ($1 \leq \beta_0 < 2$), voire la possibilité d'un comportement accidentel (modèle exponentiel, $\beta_0 = 1$) comme de vieillissement accéléré ($\beta_0 \geq 2$), tout en conservant un certain flou dans ces hypothèses ($\sigma_\beta \gg 0.5$). Il est donc peu raisonnable de ne jamais obtenir de cohérence entre *a priori* et données, et par conséquent important de contrôler la validité de la connaissance de l'expert, si les données sont supposées correctes.

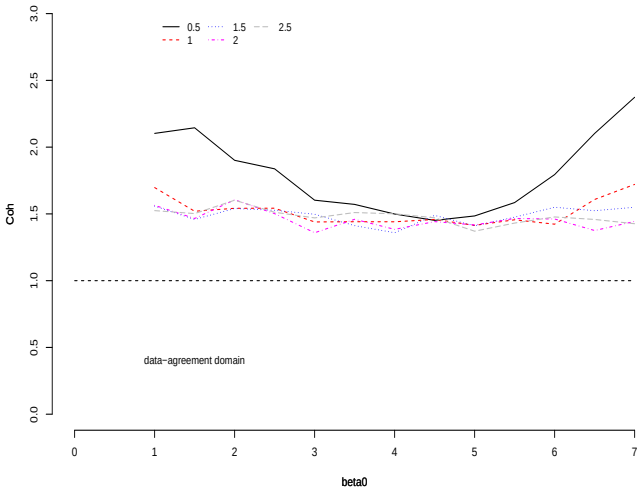


FIG. 4 – Évolutions du critère $\mathscr{C}oh_{AR}(\pi;\mathbf{X_n})$ pour l'expertise $\mathscr{E}_1$, en fonction de β_0 et σ_β.

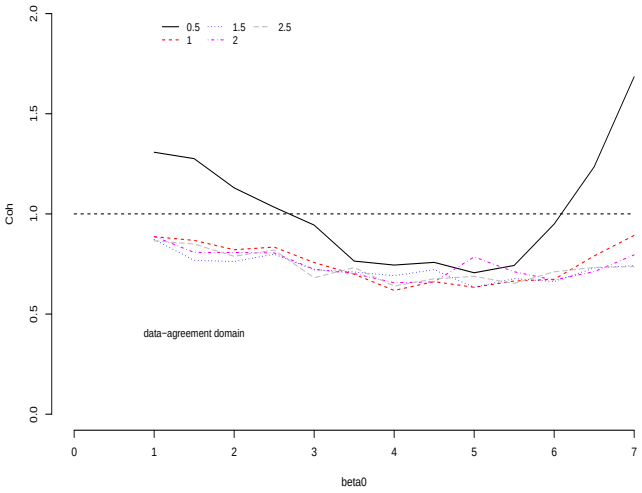


FIG. 5 – Évolutions du critère $\mathscr{C}oh_{AR}(\pi;\mathbf{X_n})$ pour l'expertise $\mathscr{E}_2$, en fonction de β_0 et σ_β.

Conclusion

La fiabilité constitue un domaine pour lesquelles les notions de cohérence entre plusieurs sources d'informations sont naturelles et utiles. L'utilisation d'opinions d'expert est fréquente dans de nombreuses études industrielles où les données de durée de vie sont collectées avec difficulté. L'une des propriétés les plus intéressantes de notre critère est de sélectionner des distributions *a priori* de biais et de variance raisonnables vis-à-vis des données. Ainsi, nous proposons d'utiliser ce critère comme un outil de calibration lorsque peu ou pas de connaissance critique n'est disponible sur l'expert.

Supposons que les données soient considérées comme correctes, et que la modélisation π de l'expertise se présente sous la forme $\pi(\theta) = \pi(\theta|\omega,\theta_e)$ où θ_e reflète la connaissance ponctuelle de θ élicitée d'après le point de vue de l'expert, et ω est un hyperparamètre contrôlant l'incertitude *a priori*. On sélectionne alors ω tel que $\mathscr{C}oh(\omega;\mathbf{X_n}) = 1$. On rend ainsi l'expert aussi informatif qu'un minimum de connaissance acceptable pour le problème.

Par ailleurs, la version arithmétique (2) offre une alternative stable au problème d'élicitation de distributions faiblement informatives, supposées modéliser cette connaissance minimale que peut apporter un expert sans biais. Si une règle de sélection permet de hiérarchiser ce choix, l'obtention de candidats nombreux et maniables reste un problème ouvert, particulièrement lorsque la dimension de θ grandit.

De façon plus générale, le risque est important de n'obtenir que des candidats trop informatifs. Ainsi, dans le cas exponentiel, la densité conjuguée π_C^{MIA} modélise la connaissance d'une donnée, et le critère (1) ne validera pas d'*a priori* jugés trop peu informatifs (par exemple, $\pi(\lambda) = \mathscr{G}(0.5, 0.5\hat{X})$). Ces derniers sont pourtant légitimement acceptables lorsqu'ils ne sont pas biaisés par rapport aux données. Il est donc nécessaire de chercher à définir la plus faible connaissance disponible pour un problème donnée, par exemple en pondérant les candidats précédemment construits (cf. [8]).

Remerciements

Les auteurs remercient Jean-Michel Marin (INRIA, CEREMADE, Université Paris Dauphine) pour son aide précieuse durant le travail de recherche. Cette étude s'inscrit dans le travail de thèse de Nicolas Bousquet au sein de l'équipe SELECT de l'INRIA Futurs et de l'Université Paris XI.

Références

[1] Angers, J.F. Credence and Robustness Behavior, *Metron*, 2000, 58, 81-108.

[2] Bacha, M., Celeux, G., Idée, E., Lannoy, A. et Vasseur, D. *Estimation de modèles de durées de vie fortement censurées*, 1998, Eyrolles : Paris.

[3] Berger, J.O et Bernardo, J.M. On the development of reference priors (with discussion). In : J.M. Bernardo, J.O. Berger, A.P. Dawid and A.F.M. Smith, Eds., *Bayesian Statistics*, 1992, Vol.4, Oxford University Press, Oxford, 35-60.

[4] Berger, J.O. et Perrichi, L.R. The Intrinsic Bayes Factor for Model Selection and Prediction, *Journal of the Americal Statistical Association*, 1996, Vol.91, No.433, Theory and Methods.

[5] Berger, J.O., Perrichi, L.R. et Varshavsky, J.A. Bayes Factors and Marginal Distributions in invariant si-

tuations, *Sankhya : The Indian Journal of Statistics*, 1998, 60, 307-321.

[6] Berger, J.O. et Pericchi, L.R. Training Samples in Objective Bayesian Model Selection, 2002, ISDS Discussion Paper 02-14.

[7] Bousquet, N. Subjective Bayesian statistics : agreement between prior and data, *Rapport de recherche 5900*, INRIA, 2006.

[8] Bousquet, N. & Celeux, G. Measures of Bayesian discrepancy between prior beliefs and data knowledge, Actes du congrès ESREL 2006, Lisbonne, Portugal, 2006.

[9] Clarke B.S. *Asymptotic Normality of the Posterior in Relative Entropy*, IEEE Trans. Infor. Theory, 1999, 45,1,165-176.

[10] Cover, T.M. and Thomas, J.A. *Elements of Information Theory*, 1991, New York : Wiley.

[11] Datta, G.S. and Ghosh, J.K. On priors providing frequentist validity for Bayesian inference, *Biometrika*, 1995, 82, pp.37-45.

[12] Datta, G.S. On priors providing frequentist validity for Bayesian inference for multiple parametric functions, *Biometrika*, 1996, **83**, 287-298.

[13] B. Dumon, F. Guérin, E. Usureau, Compatibilité entre connaissance a priori et observations de vraisemblance, Applications Industrielles de la Démarche Bayésienne, Journée de l'IMdR-SdF (16 oct. 2003, Nancy). Egalement "Démarche Bayésienne et applications à la sûreté de fonctionnement", chap. 7 et 9, Editions Hermès-Lavoisier.

[14] Idée, E., Lannoy, A. and Meslin, T. *Estimation of a lifetime law for equipment on the basis of a highly right multicensored sample and expert assessments*, 2001, preprint of LAMA team, 01-10b, Université de Savoie.

[15] Lawless, J.F. *Statistical Models and Methods for Lifetime Data*, Wiley series in probability and mathematical statistics, 1982.

[16] O'Hagan, A. On outlier rejection phenonema in Bayes inference, *J. Roy. Statist. Soc. B*, 1979, **41**, 358-367.

[17] O'Hagan, A. *Modelling with heavy tails*. J. M. Bernardo et al (Eds.), *Bayesian Statistics 3*, 1988, 345-359. Oxford University Press.

[18] O'Hagan, A. On outliers and credence for location parameter inference. *Journal of the American Statistical Association 85*, 1990, 172- 176.

[19] O'Hagan, A. (Eliciting expert beliefs in substantial practical applications, *The Statistician*, 1998, **47**, Part.1, 21-35.

[20] O'Hagan, A. HSSS model criticism (with discussion). In Highly Structured Stochastic Systems, P. J. Green, N. L. Hjort and S. T. Richardson (eds), 2003, 423-453. Oxford University Press.

[21] Pérez, J.M. *Development of Conventional Prior Distributions for Model Comparisons*, 1998, Ph.D. Thesis, Purdue University.

[22] Pérez, J.M. and Berger, J. Expected posterior prior distributions for model selection, *Biometrika*, 2002, 89, 491-512.

[23] Robert, C.P. *The Bayesian Choice. From Decision-Theoretic Motivations to Computational Implementation. (second edition)*, Springer-Verlag : New York, 2001

[24] Sun, D. A note on noninformative priors for Weibull distributions, *Journal of Statistical Planning and Inference*, 1997, 1, 319-338.

[25] E. Usureau, Application des méthodes pour l'optimisation des coûts de développement des produits nouveaux, Thèse de doctorat, Angers, 2001.