ENCADREMENT ET ESTIMATION DE PROBABILITÉS DE DÉFAILLANCE DANS UN CADRE MONOTONE D'ANALYSE DE FIABILITÉ STRUCTURALE

BOUNDING AND ESTIMATING FAILURE PROBABILITIES IN MONOTONIC STRUCTURAL RELIABILITY FRAMEWORKS

A.-L. Popelin et R. Sueur et N. Bousquet
EDF R&D, Département MRI
6 quai Watier, 78401 Chatou, France
anne-laure.popelin@edf.fr

Résumé
Plusieurs démarches existent afin de modéliser, évaluer ou encore justifier la fiabilité d'un composant ou d'un système. Lorsque aucune donnée n'est disponible sur l'historique de dégradation ou de défaillance du système n'est disponible, une démarche courante consiste à modéliser le composant étudié par un code informatique prenant en entrée des paramètres (par exemple des grandeurs physiques, des informations sur l'environnement, etc.) et donnant en sortie un indicateur de fiabilité associé aux paramètres donnés. L'incertitude affectant les paramètres d'entrée étant couramment modélisée de façon probabiliste, cet indicateur est souvent une probabilité que la sortie de code dépasse un certain niveau de risque. Si de nombreuses méthodes ont été développées pour estimer cette probabilité à partir de plans d'expériences numériques lorsque le code est lourd d'exécution et interdit un grand nombre d'essais, les propriétés de forme de la sortie du code restent en général peu exploitées. Cet article vise à présenter les bénéfices liés à la prise en compte de la monotonie du code (fréquente en fiabilité), en particulier la possibilité de borner cette probabilité de défaillance de façon déterministe, ainsi que l'accélération de ce calcul par rapport à des méthodes classiques.

Abstract
One of the major approaches used to quantify the failure probability of a highly reliable industrial component, for which no failure data is available, is to make use of computer experiments reproducing the physical phenomena of forcing and degradation and more generally the environmental processes affecting the reliability of the component. Often mathematically described as deterministic functions with random physical inputs, these computer codes represent expert approaches to the problem. Their outputs are thus typically random, and statistical tools can be used to estimate the failure probability. However, such code runs are usually time-consuming, therefore a large panel of methods has been developed to account for a low or moderate computational budget. The form constraints on the code output remain however little exploited, especially the properties of monotonicity that can be frequently encountered in such reliability studies. Therefore this article aims at presenting the benefits of accounting for this property in structural reliability analysis: the probability can be deterministically bounded and its estimation can be considerably accelerated in terms of computational budget.

Contexte

De nombreux systèmes industriels complexes, faisant l'objet d'opérations de maintenance, présentent une forte fiabilité dont témoigne l'absence de retour d'expérience (REX) de défaillance. La quantification du risque associé peut donc nécessiter de disposer d'un code numérique déterministe $g(X)$ reproduisant le phénomène mis en jeu en fonction de grandeurs d'entrée X vivant dans un espace Ω (typiquement des paramètres physiques tels que la température, la pression, etc.). Souvent, une défaillance du système soumis au phénonème considéré peut être formellement décrite par la survenue d'un évènement $Z \leq Z_0$ où $Z = g(X)$ et Z_0 est une valeur-seuil. On définit classiquement g tel que Z s'écrive $Z = R - S$ où R représente une *résistance* et S une *sollicitation*, et le seuil de défaillance prend alors la valeur $Z_0 = 0$. Pour tenir compte des incertitudes inhérentes à la connaissance du phénomène, les entrées (et le bruit de modèle affectant le code g, souvent décrit comme une entrée supplémentaire) sont généralement considérées comme des variables aléatoires dont les lois émanent d'études de quantification basées sur des données de REX et d'expertise. On notera donc X le vecteur *probabilisé* de ces variables d'entrées et de bruit, et P la distribution de probabilité de X, de densité $f(x)$. Dans ce cadre dit d'analyse de fiabilité des structures, l'évaluation de ce risque implique, pour l'ingénieur fiabiliste, de pouvoir disposer d'un estimateur de la probabilité de défaillance

$$p \quad = \quad P(g(X) \leq 0) \; = \; \int_{\Omega} \mathbb{1}_{\{g(x) \leq 0\}} f(x) \, dx. \qquad \{1\}$$

Deux grandes approches de l'estimation de cette probabilité sont utilisées en analyse de fiabilité des structures. Les méthodes FORM/SORM traitent l'estimation comme un problème d'optimisation, tandis que les méthodes de simulation utilisent une panoplie de tirages des valeurs d'entrée (ou plan d'expérience) pour produire un estimateur statistique de la probabilité. Un exemple classique de méthode est l'estimation de Monte Carlo. Chacune de ces classes de méthode souffre de défauts qui limitent son utilisation. L'erreur faite sur les estimateurs fournis par les méthodes FORM/SORM est en général peu contrôlable, tandis que les méthodes de Monte Carlo et Quasi Monte Carlo peuvent rapidement nécessiter un coût d'appel au code prohibitif en temps de calcul. Ainsi, une vaste littérature scientifique s'est emparée du sujet, afin d'améliorer les outils existants.

Cet article vise à sensibiliser la communauté des ingénieurs fiabilistes au gain potentiel, en termes de précision d'estimation et d'encadrement déterministe de la probabilité de défaillance p, apporté par la prise en compte d'une contrainte de forme intuitive sur le comportement du code g. On suppose en effet que $x : \Omega \mapsto g(x)$ est une fonction monotone, ce qui fait sens dans de nombreux problèmes physiques. L'exemple réel traité dans cet article considère ainsi la résistance d'une composant passif d'une centrale nucléaire. Cette résistance est une fonction décroissante (entre autres) de la taille générique des défauts de fabrication (micro-fissures) et de la température du fluide, agissant comme une contrainte thermique. Inversement, elle est croissante en fonction de l'épaisseur de la paroi, de l'éloignement des défauts de fabrication vis-à-vis de la surface de la paroi, etc.

Dans un premier temps, nous rappelons un certain nombre de méthodes d'estimation de p couramment utilisées dans le monde ingénieur car relativement automatisables et implémentées dans de nombreux outils logiciels (ex: OpenTURNS). Puis nous montrons que toutes les méthodes d'estimation de p peuvent tirer parti de la monotonie de g pour fournir des bornes déterministes sur p. Nous décrivons ensuite les principes d'une nouvelle classe de méthodes s'appuyant sur cette monotonie pour chercher à minimiser le nombre d'appels au code g. Si cette méthode permet théoriquement d'améliorer significativement la rapidité et la robustesse de l'estimation par rapport au cadre Monte Carlo classique, des comparaisons numériques sont menées pour tester le pouvoir d'estimation et d'encadrement réel de ces méthodes. Pour cela, un exemple-jouet générique permettant la montée en dimension est utilisé, en préalable au traitement du cas réel décrit plus haut.

Quelques méthodes classiques d'estimation de p

Les méthodes décrites ci-après sont classées en deux grandes familles : les méthodes d'approximation approchent le problème comme un problème d'optimisation; les méthodes dites de simulation proposent le calcul de l'intégrale via la couverture de l'espace par un ensemble de tirages aléatoires.

1.1 Méthodes d'approximation courantes : FORM/SORM

Classiquement utilisées dans le monde ingénieur pour leur très faible coût computationnel, les méthodes FORM/SORM sont bien connues (Anonymous, 2011) et nous n'en donnons qu'un rappel rapide. Ces méthodes nécessitent au préalable une transformation isoprobabiliste du vecteur d'entrée. Pour un vecteur aléatoire d'entrée X , F_i étant la distribution marginale de la composante i et C sa fonction copule, une transformation isoprobabiliste T est un diffémorphisme de Supp(X) dans $\mathbb{R}^n$, tel que le vecteur aléatoire $U = T(X)$ et RU aient la même distribution pour toutes les rotations R. Parmi l'ensemble de ces transformations, les plus utilisées sont la transformation de Nataf (copules gaussiennes), sa généralisation (Dutfoy & Lebrun, 2009) (copules elliptiques) et la transformation de Rosenblatt, sans condition sur la forme de la copule. Le vecteur U est ainsi l'image de X dans l'espace standard, X étant dans l'espace physique. La probabilité de défaillance devient alors :

$$p \quad = \quad P(g(U) \leq 0) \; = \; \int_{\mathbb{R}^n} \mathbb{1}_{\{g(u)\leq 0\}} f_U(u)\, du$$

où $f_U(u)$ est la densité du vecteur d'entrée dans l'espace transformé. Via une procédure d'optimisation sous contrainte, le calcul du point de conception P^*, défini par le projeté du point de fonctionnement (origine de l'espace transformé) sur la surface d'état-limite $\mathscr{S} = \{x \in \Omega$ (ou *surface de défaillance*) dans cet espace (cf. Figure 1), constitue la seconde étape des méthodes FORM/SORM. FORM et SORM diffèrent par l'approximation (linéaire ou quadratique) qui est faite de cette surface. Enfin, la probabilité p est estimée par $\Phi(\beta_{HL})$, où β_{HL} est la distance entre le point de fonctionnement et P^* (cf. Figure 1). Si ces deux méthodes peuvent en pratique rapidement donner des ordres de grandeur approximatifs de p, le contrôle de l'estimateur proposé de p, qui n'est donc pas statistique, reste théoriquement peu évident.

1.2 Méthodes de simulation : Monte-Carlo et Monte Carlo accélérées

Les méthodes de simulation, ou méthodes d'échantillonnage, utilisent un grand nombre de tirages des variables d'entrée pour produire un estimateur statistique de la probabilité de défaillance, dont l'expression est rappelée ci-dessous. Nous rappelons ci-dessous les plus usuelles de ces méthodes, au sens où elles sont très présentes au sein des outils de calcul du commerce, et renvoyons le lecteur à Kroese & Rubinstein (2007) pour des détails techniques.

La méthode de Monte-Carlo consiste à simuler un échantillon de N réalisations $x_1, \ldots, x_N \sim f$ du vecteur des entrées aléatoires, afin d'estimer p par $\hat{p}_N = \sum_{i=1}^N \mathbb{1}_{\{g(x_i)\leq 0\}}/n$, estimateur dont la variance exacte est $p(1-p)/N$. Les propriétés de la loi binomiale ou le théorème central limite permettent alors de proposer des intervalles de confiance exacts ou asymptotiques. Le coefficient de variation $\mathrm{CV}[\hat{p}_n] = \sqrt{(1-p)/(pN)}$ offre une mesure de la dispersion de l'estimateur et une "règle de l'ingénieur" permettant d'évaluer le nombre de tirages N nécessaires pour atteindre une précision suffisante: si l'on vise un coefficient de variation de l'estimateur de l'ordre de 10% et que la probabilité à estimer est autour de 10^{-a}, la taille N de l'échantillon doit être au moins égale à 10^{a+2}. Les deux principages faiblesses de cette méthode sont donc à la fois théorique et appliquée : d'une part la dispersion augmente lorsque $p \to 0$ (manque de *robustesse*), mais de plus, si p est faible, le nombre de tirages devient rapidement très élevé et peut, si la fonction g est coûteuse en temps de calcul, compromettre l'applicabilité de la méthode. Les méthodes rappelées brièvement ci-après tentent de pallier le problème de nombre d'appels au code, en faisant appel à un tirage "intelligent" des points dans l'espace Ω. Ce plan d'expérience numérique, noté DOE (pour *design of experiments*), peut être produit selon des méthodes déterministes ou stochastiques.

1. **Tirage d'importance.** Le principe de cette méthode d'échantillonnage est de remplacer la densité initiale f du vecteur d'entrées par une densité plus "efficace" $\tilde{f}$, en termes de nombre de défaillance associé. Puisque la partie du domaine des possibles qui est étudié est le domaine de défaillance, cette méthode propose de "recentrer" les tirages autour de ce domaine de défaillance. L'estimateur de la probabilité de défaillance s'écrit alors

$$\hat{p}_n \quad = \quad \frac{1}{N}\sum_{i=1}^N \mathbb{1}_{\{g(x_i)\leq 0\}} \frac{f(x_i)}{\tilde{f}(x_i)} \quad \text{avec } x_1, \ldots, x_N \overset{iid}{\sim} \tilde{f}.$$

   Dans les expériences menées plus loin, cette méthode sera couplée à FORM (notée FORM-IS), en utilisant une densité d'importance gaussienne réduite, centrée en le point de conception u^*.

2. **Tirage directionnel.** Cette méthode nécessite une transformation isoprobabiliste préliminaire dans l'espace gaussien standard, comme les méthodes FORM/SORM. Elle consiste en un sondage aléatoire de l'espace par la simulation de directions et de rayons d'échantillonnage, et propose une estimation de p découpées en quadrants spatiaux.
3. **LHS.** La méthode dite du tirage hypercube latin (Latin Hypercube Sampling, en anglais, LHS) propose, pour accroître la précision de l'estimateur tout en diminuant le nombre d'appels au code, de couvrir "au mieux" le domaine de variation des variables d'entrée, en utilisant une stratification de l'espace. Le domaine de variation de chaque entrée est découpé en intervalles équiprobables. L'échantillonnnage est ensuite effectué de telle sorte que marginalement (c'est-à-dire en projection sur chaque axe) les points sont uniformément répartis.
4. **Quasi Monte-Carlo.** Les méthodes dites de Quasi Monte-Carlo utilisent, au lieu d'un échantillonnage aléatoire, des suites à discrépance faible, cherchant là encore à obtenir une couverture régulière de l'espace Ω. Le théorème central limite ne pouvant être appliqué sur des suites non-aléatoires, la convergence de l'estimateur peut néanmoins être obtenu, par l'inégalité de Koksma-Hlawka. L'erreur de l'estimateur de p converge en $\mathcal{O}(logN/N)$, contre une convergence en $\mathcal{O}(1/\sqrt{N})$ pour un Monte-Carlo classique.

Prise en compte de la monotonie du code

Le code déterministe g est souvent considéré comme une "boîte noire" par le fiabiliste, car il s'agit d'une succession de résolution d'équations (typiquement physiques) par des opérations coûteuses impliquant en général de la discrétisation sur des maillages, et donc une complexité élevée. La régularité de g est une hypothèse parfois forte, car elle néglige les effets falaises qui peuvent survenir en particulier lorsqu'on s'approche de la surface de défaillance $\mathscr{S} = \{x \in \Omega,\ g(x) = 0\}$. Le refus d'une hypothèse d'absolue continuité de g peut ainsi invalider les techniques visant à reproduire, ou *émuler*, le comportement du code au moyen d'outils comme les processus stochastiques continus calibrés à partir de DOEs. *A fortiori*, des hypothèses de différentiabilité (sur lesquelles s'appuient les algorithmes FORM/SORM) résultent d'une connaissance relativement approfondie de g, et celui-ci n'apparaît plus guère, dans les faits, que comme une "boîte grise".

Cependant, l'hypothèse de monotonie sur g peut se révéler sous-jacente, sinon intuitive, en particulier dans un cadre fiabiliste. En témoigne le fréquent principe conservatif qui propose de calculer $Z_p = g(x_p)$ où x_p est un vecteur de valeurs *pénalisées* (plutôt qu'un vecteur aléatoire) représentant un "pire" état du système considéré, et de vérifier que $Z_p > 0$. La notion de "pire" suppose en effet que les effets cumulés de valeurs pénalisées en entrée de g mènent à des comportement extrêmes du système, et implique donc la monotonie de g.

Mis en lumière par de Rocquigny (2009); Limbourg *et al.* (2010) puis Rajabalinejad *et al.* (2011), le principal bénéfice de la monotonie de g, associé à la continuité et la simple connexité de la surface de défaillance $\mathscr{S} = \{x \in \Omega,\ g(x) = 0\}$, est la possibilité d'utiliser tout DOE pour proposer un encadrement déterministe de p, en sus de toute estimation statistique. La figure 2 permet d'illustrer ce principe dans un cas bidimensionnel simple. De part et d'autre de $\mathscr{S}$, un DOE D_n formé de n points définit deux ensembles notés $\mathbb{U}_n^-$ et $\mathbb{U}_n^+$ tels que

$$\begin{aligned} \mathbb{U}_n^- &= \{x \in \Omega \text{ tel que } x \preceq y \text{ où } y \in D_n \text{ et } g(y) \leq 0\}, \\ \mathbb{U}_n^+ &= \{x \in \Omega \text{ tel que } x \succeq y \text{ où } y \in D_n \text{ et } g(y) > 0\} \end{aligned}$$

et où l'ordre partiel $\succeq$ est défini par, $\forall (x,y) \in \Omega$,

$$x \succeq y \quad \Leftrightarrow \quad x_k \geq y_k \quad \forall i \in \{1,\ldots,d\}.$$

Sur la figure 2, les points $x_a,\ldots,x_g$ sont des éléments du DOE D_n qui déterminent la frontière du sous-espace $\mathbb{U}_n^-$, et correspondent à des scénarios menant à la défaillance. Tous les points de Ω qui leur sont plus petits (au sens de l'ordre partiel) sont ausi défaillants. Inversement, les points $x_h,\ldots,x_n$ déterminent la frontière du sous-espace de *sécurité* $\mathbb{U}_n^+$. La probabilité p recherchée correspond au volume de l'espace Ω situé en-dessous de $\mathscr{S}$ au sens de l'ordre partiel. On trouve donc l'encadrement suivant :

$$p_n^- = \text{Vol}(\mathbb{U}_n^-) \quad \leq\ p\ \leq \quad p_n^+ = 1 - \text{Vol}(\mathbb{U}_n^-).$$

Le calcul de ces bornes peut être effectué de façon exacte (Bousquet, 2012) lorsque les entrées du code sont supposées indépendantes et uniformes sur $[0,1]^d$, comme sur la figure 2. On remarquera qu'on peut toujours se ramener à ce cas lorsque les entrées "physiques" y de g sont indépendantes ; en effet, il suffit de poser $x = F(y)$ où F est la fonction de répartition de la variable aléatoire "physique" Y, et le code utilisé devient $\tilde{g} = g \circ F^{-1}$, qui conserve ses propriétés de monotonie. Les algorithmes de géométrie computationelle permettant ce calcul souffrent néanmoins d'un coût exponentiel en d, ce qui les rend peu utilisables en pratique dès la dimension 4. Dans un cas plus général, on préfèrera donc une méthode de Monte Carlo standard, insensible à la dimension de l'espace des entrées. Un échantillon $(x_1,\ldots,x_M)$ de taille $M = (1/p_0)^k$ est simulé, avec $k \geq 2$ et p_0 une évaluation *a priori* de p, et on estime (p_n^-, p_n^+) par

$$\hat{p}_{n,M}^- \quad = \quad \frac{1}{M}\sum_{i=1}^{M} \mathbb{1}_{\{x_i \in \mathbb{U}_n^-\}}, \qquad \hat{p}_{n,M}^+ \ = \ 1 - \frac{1}{M}\sum_{i=1}^{M} \mathbb{1}_{\{x_i \in \mathbb{U}_n^+\}},$$

à la précision $\simeq 2p^{\frac{k+1}{2}}$. Ces calculs ne nécessitent pas d'appels à g mais $\rho_n nM$ opérations de tri selon l'ordre partiel où ρ_n est la fraction des points du DOE D_n délimitant les frontières de $(\mathbb{U}_n^-, \mathbb{U}_n^+)$.

Tirer parti de la monotonie pour accélérer l'estimation de p. Lorsque le DOE est choisi de façon stochastique, c'est-à-dire lorsque le plan d'expérience séquentiel est *simulé* plutôt que choisi de façon déterministe dans la suite des espaces non-dominés $\mathbb{U}_0 \supset \mathbb{U}_1 \supset \ldots \supset \mathbb{U}_n$, on peut également produire en parallèle des bornes une estimation statistique de p. Rajabalinejad *et al.* (2011) puis Bousquet (2012) s'intéressent en particulier au cas où le tirage est produit uniformément dans cette suite d'espaces imbriqués. Cette méthode permet de produire un estimateur de Monte-Carlo *adapté* (Rajabalinejad *et al.*, 2011), de variance significativement plus faible que celle de Monte-Carlo standard. Mais Bousquet (2012) propose un nouvel estimateur de p reposant sur la maximisation d'une vraisemblance de données de Bernoulli dépendantes, qui atteint théoriquement la borne de Cramer-Rao pour l'échantillonnage considéré, c'est-à-dire un minima de variance (et donc un maxima d'accélération). Il montre aussi la consistance forte des bornes (devenues processus aléatoires), ce qui permet de justifier le choix de la borne supérieure comme estimateur statistique conservatif. Cette seconde méthode appelée *Monotonic Reliability Method* (MRM), par analogie

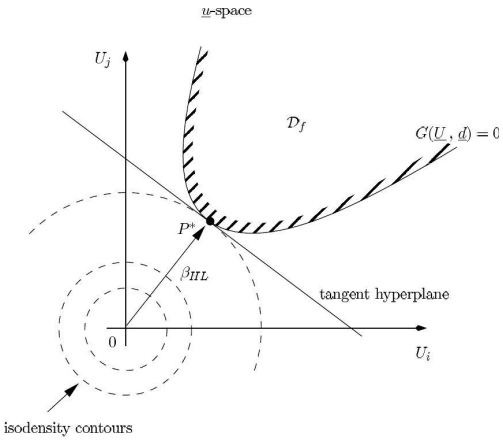


Figure 1: Approximation linéaire (FORM) de la surface de défaillance *(tiré de Anonymous (2011))*.

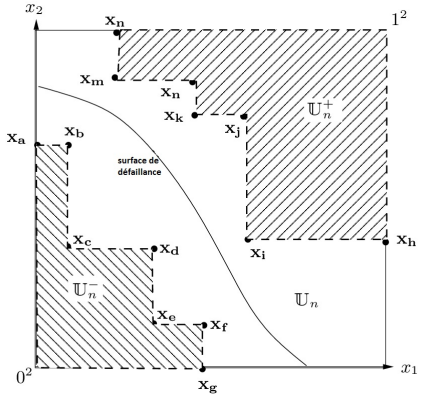


Figure 2: Frontières de deux ensembles de points dans l'espace Ω (ici réduit au cube $[0,1]^d$) dominant des points menant à la défaillance (en-dessous de la surface de défaillance $\mathscr{S}$) ou menant à la non-défaillance (au-dessus de $\mathscr{S}$). Les frontières sont délimités par des points du DOE D_n.

avec FORM/SORM (*First/Second Order Reliability Methods*), est ici mise en application.

Application à un exemple-jouet

Afin de tester les performances de l'algorithme MRM et de comparer celles-ci à différentes méthodes couramment utilisées dans le domaine de la fiabilité, on construit un exemple-jouet, c'est à dire une fonction simple permettant des calculs rapides et donc un grand nombre d'appels au code. Pour la dimension 2, on choisit :

$$g(x_1,x_2) = 2x_2\sqrt{x_1} - 1$$

On peut aisément vérifier la monotonie de cette fonction et que les limites en $(0,0)$ et $(1,1)$ sont respectivement -1 et 1. De plus, pour toute valeur de seuil α fixé dans $[-1,1]$, la probabilité de dépassement de α peut être calculé analytiquement. Nous ne détaillons pas ici le calcul du seuil en fonction de la probabilité cible à estimer. L'algorithme MRM est testé, pour la fonction g, avec des p de 10^{-n} pour $n = 3,4,5$, afin d'étudier sa sensibilité à la valeur de la probabilité estimée. En effet, il est attendu que, de même que pour un algorithme Monte-Carlo classique, une faible probabilité de dépassement de seuil nécessitera un plus grand nombre d'appel au code pour être estimée avec une robustesse acceptable. Les trois cas ont donnés une estimation très fine de la probabilité de défaillance, égale aux estimations des bornes inférieures et supérieures, en moins de 1000 appels au code. On rappelle que dans ces trois cas, pour obtenir une estimation de la probabilité de défaillance avec un coefficient de variation de 10%, la méthode de Monte-Carlo nécessite entre 10^{-5} à 10^{-7} appels à la fonction g.

La sensibilité des performances MRM au fléau de la dimension (c'est-à-dire à l'augmentation du nombre d'entrées stochastiques) est également testée. De nombreuses méthodes, performantes en petites dimensions, souffrent de la nécessité, parfois rédhibitoire, d'un nombre d'appels au code significativement plus grand. La probabilité de défaillance a donc été estimée, à l'aide de nombreuses méthodes "'classiques"' et de l'algorithme MRM, sur les fonctions suivantes:

$$\begin{aligned} g(x_1,x_2,x_3) &= 2\sqrt{x_1}x_2\sqrt{x_3)} - 1, \\ g(x_1,x_2,x_3,x_4) &= 2\sqrt{x_1}x_2\sqrt{x_3}x_4 - 1, \\ g(x_1,x_2,x_3,x_4,x_5,x_6) &= 2\sqrt{x_1}x_2\sqrt{x_3}x_4\sqrt{x_5}x_6 - 1. \end{aligned}$$

Les résultats des tests sont présentés sur les tableaux 1 à 4. Pour chaque méthode testée, le nombre d'appels au code réalisé est précisé. Quand il est disponible, le coefficient de variation de l'estimateur est également donné. Notons que, concernant la méthode FORM-IS, le nombre d'appels au code donné ne concerne que le tirage d'importance réalisé, et qu'il faut lui ajouter le nombre d'appels au code réalisé par FORM pour avoir la réelle valeur du nombre de calculs effectués. L'encadrement déterministe de l'estimateur obtenu par la méthode FORM-IS est également fourni.

Le nombre d'appels au code permettant d'obtenir une précision donnée sur l'estimation de la probabilité de défaillance est très inférieur à celui que requiert un algorithme de Monte-Carlo simple, et il est comparable aux performances d'algorithmes de certaines approches de Monte-Carlo accélérées pour des codes à un petit nombre de variables. Soulignons l'intérêt d'un code MRM fournissant un encadrement certain de la probabilité de défaillance, quand les méthodes d'échantillonnage classiques donnent un intervalle de confiance stochastique. Enfin, le DOE de l'agorithme MRM est beaucoup plus efficace pour tirer parti de la monotonie que le DOE de la méthode FORM-IS : l'encadrement obtenu est toujours plus précis avec celui-ci.

	FORM	Monte Carlo	LHS	FORM-IS	Quasi Monte Carlo	Directionnel	MRM
Nombre d'appels	186	93827	91941	355	100000	2	600
p	7.942e-4	1.066e-3	1.088e-3	9.959e-4	9.6e-4	1.334e-3	1e-3
Coeff. de var.	-	9.9%	9.9%	9.9%	-	9.8%	-
Borne inf.	-	-	-	1.6e-5	-	1.526e-5	1e-3
Borne sup.	-	-	-	9.84e-1	-	9.844e-1	1e-3

Table 1: Résultats des différentes estimations de probabilité de défaillance sur le cas-jouet à 2 dimensions.

	FORM	Monte Carlo	LHS	FORM-IS	Quasi Monte Carlo	Directionnel	MRM
Nombre d'appels	226	54588	46290	379	100000	220	600
p	1.245e-3	1.832e-3	2.160e-3	1.850e-3	1.92e-3	2.212e-3	2.508e-3
Coeff. de var.	-	9.9%	9.9%	9.9%	-	9.9%	-
Borne inf.	-	-	-	7e-6	-	-	1.308e-3
Borne sup.	-	-	-	9.313e-1	-	-	3.708e-3

Table 2: Résultats des différentes estimations de probabilité de défaillance sur le cas-jouet à 3 dimensions.

	FORM	Monte Carlo	LHS	FORM-IS	Quasi Monte Carlo	Directionnel	MRM
Nombre d'appels	272	53453	51531	855	100000	346	600
p	6.581e-4	1.871e-3	1.941e-3	1.579e-3	1.8e-3	1.374e-3	7.893e-3
Coeff. de var.	-	9.9%	9.9%	9.9%	-	9.9%	-
Borne inf.	-	-	-	5e-6	-	-	1.560e-4
Borne sup.	-	-	-	8.527e-1	-	-	1.563e-2

Table 3: Résultats des différentes estimations de probabilité de défaillance sur le cas-jouet à 4 dimensions.

	FORM	Monte Carlo	LHS	FORM-IS	Quasi Monte Carlo	Directionnel	MRM
Nombre d'appels	465	43570	40098	1285	100000	515	600
p	7.454e-4	2.295e-3	2.494e-3	2.480e-3	1.95e-3	1.916e-3	9.387e-2
Coeff. de var.	-	9.9%	9.9%	9.9%	-	9.9%	-
Borne inf.	-	-	-	0.000	-	-	2.000e-6
Borne sup.	-	-	-	6.621e-1	-	-	1.877e-1

Table 4: Résultats des différentes estimations de probabilité de défaillance sur le cas-jouet à 6 dimensions.

Application réelle : code thermo-mécanique pour l'amorce de fissure

Un code thermo-mécanique G permet à EDF de modéliser le comportement d'un composant passif d'une centrale nucléaire. Le comportement de ce composant dépend de différents paramètres dont l'épaisseur d'un revêtement en inox appliqué en paroi interne, la température du fluide en contact avec la paroi et la ténacité de l'acier de la structure, grandeur rendant compte de la capacité du métal à résister à l'amorçage d'une fissure. Ce composant peut, en situation incidentelle, être soumis à un fort gradient de température induisant des contraintes importantes dans l'épaisseur de la paroi. Ce code permet de calculer un facteur de marge, défini comme le rapport entre la ténacité du matériau soumis à une sollicitation et l'intensité de la contrainte appliquée. Ainsi, un facteur de marge inférieur à 1 signifie l'amorçage d'une fissure. L'amorçage d'une fissure ne peut avoir lieu que si un défaut existe dans le métal de la paroi, ainsi le code prend également en entrée les dimensions d'un " défaut supposé " au point d'amorçage. Le risque d'amorçage de fissure est une fonction monotone des entrées suivantes, rendues stochastiques :

- T, la température du fluide injecté, responsable de la sollicitation thermique
- l_{rev}, l'épaisseur du revêtement interne
- K_{1c}, la ténacité de l'acier
- H, la hauteur du défaut
- L, la longueur du défaut

Les variables T et l_{rev} suivent des lois uniformes et la variable K_{1c} suit une loi normale. Toutes sont considérées comme indépendantes. La hauteur H et la longueur L d'un défaut suivent par contre des distributions corrélées. La loi marginale de H est la Weibull $\mathscr{W}(\eta,\beta)$ de fonction de répartition $F_H(h) = 1-\exp(-(h/\eta)^\beta)$, tandis que conditionellement à H, L suit la loi lognormale définie par

$$L \quad = \quad H\exp(\varepsilon)$$

où $\varepsilon \sim \mathscr{N}(\mu,\sigma^2)$ tronqué de façon à vérifier $H < L$. On peut alors écrire

$$G(T,l_{rev},K_{1c},H,L) \quad = \quad G\circ T^{-1}(x_1,x_2,x_3,x_4,x_5) \; = \; g(x_1,x_2,x_3,x_4,x_5)$$

où $(x_1,x_2,x_3,x_4,x_5) \overset{iid}{\sim} \mathscr{U}[0,1]$ et $T^{-1}(x_1,x_2,x_3,x_4,x_5) = (F_T^{-1}(x_1),F_{l_{rev}}^{-1}(x_2),F_{K_{1c}}^{-1}(x_3),F_H^{-1}(x_4),\mathscr{F}(x_5|x_4))$, avec

$$\mathscr{F}(x_5|x_4) \quad = \quad \exp\left(\log F_H^{-1}(x_4) + \sigma\Phi^{-1}_{-\frac{\mu}{\sigma}}(x_5) + \mu\right)$$

et où Φ_ε désigne la fonction de répartition de la loi normale centrée réduite tronquée inférieurement en ε. Cette transformation permet de mettre en oeuvre les méthodes MRM dans un hypercube $[0,1]^5$ où toutes les lois uniformes sont indépendantes et tel que G et g aient même monotonie, ce qui est un préalable à la méthode proposée dans Bousquet (2012). Les autres paramètres en entrée du calcul sont fixés à

des valeurs telles que la probabilité de défaillance soit de l'ordre de 10^{-3}. L'estimation de la probabilité de défaillance est réalisée à l'aide de l'algorithme MRM pour le cas à 2 variables aléatoires (T et K_{1c}) puis à trois variables aléatoires (en ajoutant l_{rev}), puis le cas à dimension 5 est étudié.

Les résultats obtenus, qui seront présentés en détail durant l'exposé accompagnant cet article, révèlent un réel intérêt de l'agorithme MRM pour l'estimation de la fiabilité du système : pour le cas à 2 variables aléatoires, environ 800 calculs ont suffit à obtenir une estimation fine (égale aux bornes de l'encadrement déterministe, indisociables). Le cas à 3 variables aléatoires a nécessité environ 2500 appels au code pour un résultat aussi robuste. Les méthodes FORM utilisées sur ce problème ne fournissant pas de résultat quant à la confiance à accorder au résultat, et les méthodes d'échantillonnage ayant nécessité un nombre redhibitoire d'appel au code, cette méthode offre de nouvelles perspectives pour ce problème industriel. Le cas réel prend en entrée jusqu'à plus de 10 variables d'entrées incertaines : le travail d'évaluation de l'algorithme sur cette étude reste donc à poursuivre.

Conclusions et perspectives

Les études menées sur l'algorithme MRM permettent de mettre en évidence l'intérêt de tirer parti de la monotonie d'un code physique pour calculer un encadrement de la probabilité de défaillance ainsi qu'une estimation de cette probabilité. Les résultats obtenus sur l'exemple-jouet montrent que le nombre d'appels au code permettant d'obtenir une précision donnée sur l'estimation de la probabilité de défaillance est très inférieur à celui que requiert un algorithme de Monte-Carlo simple et comparable aux performances d'algorithmes de Monte-Carlo accéléré pour des codes à un petit nombre de variables. De plus, on peut souligner l'intérêt d'un code MRM fournissant un encadrement certain de la probabilité de défaillance, ou, de manière équivalente, un " intervalle de confiance à 100% ", contrairement aux algorithmes de type Monte-Carlo donnant un tel intervalle avec une confiance nécessairement inférieure à 100%. De plus, les méthodes d'approximation permettent d'obtenir une valeur approchée de la probabilité de défaillance en un petit nombre d'appels au code mais ne donnent aucune information sur la confiance que l'on peut avoir sur le résultat obtenu et peuvent, selon la forme du code dans l'espace des variables d'entrée, donner des résultats très peu précis ou même aberrants. Enfin, il semble que l'algorithme MRM ne subisse le fléau de la dimension que dans une mesure moins importante que les algorithmes de simulation.

Ces constatations demandent à être confirmées par une investigation plus large des potentialités des algorithmes MRM. Il semble avant tout nécessaire de pouvoir les comparer à des méthodes plus avancées d'estimation de p, comme les approches de stratification directionnelle adaptive (Garnier *et al.*, 2008) qui peuvent également tirer parti de la monotonie, ou encore les approches fondées sur un couplage de *subset simulation* (qui demande ordinairement un grand nombre d'appels au code) et un procédé d'*émulation* du code, par exemple par krigeage (Li *et al.*, 1998). Par ailleurs, les améliorations les plus sensibles des performances de l'algorithme MRM sont sans doute à attendre d'un échantillonnage séquentiel moins fruste qu'un simple tirage uniforme dans $\mathbb{U}_k$. En effet, il semble, de manière intuitive, peu utile de tirer un nouveau point proche des frontières des domaines $\mathbb{U}^+$ et $\mathbb{U}^-$. On peut donc imaginer construire un plan d'expérience séquentiel en échantillonnant les points x_k dans $\mathbb{U}_k$ de façon à minimiser un critère de distance avec la surface de défaillance $\mathscr{S}$. Parmi les méthodes envisagées pour définir un tel critère on peut, par exemple, imaginer de construire un *classifieur* s'appuyant sur les points frontières de $\mathbb{U}^+$ et $\mathbb{U}^-$, permettant de classer les points de l'espace non-dominé restant $\mathbb{U}_k$. Comme le propose Hurtado (2004), un tel classifieur (ou méta-modèle de $\mathscr{S}$) peut être obtenu à l'aide de réseaux de neurones ou de machines à support de vecteur (SVM). Cet échantillonnage, toutefois, doit rester stochastique pour deux raisons. La première est la possibilité de calculer un estimateur statistique de p en parallèle des bornes déterministes, et donc d'ajouter à une estimation conservative (la borne supérieure) une estimation sans biais. La seconde est que l'étude des propriétés théoriques d'un tel estimateur peuvent permettre de proposer des critères de progression qui, sinon, risqueraient d'être tout à fait arbitraires. Ainsi, on envisage dans les études futures de s'attacher à la calibration d'une loi d'importance simulant le prochain point, dans le sens où la variance de l'estimateur courant serait rendue minimale.

On peut enfin remarquer que la construction d'un méta-modèle de $\mathscr{S}$ offre une alternative à l'estimation progressive de la probabilité de défaillance. En effet, on peut alors supposer qu'un tirage de Monte-Carlo permette d'obtenir une estimation non biaisée de la probabilité de défaillance, à coût computationnel négligeable. Le travail à mener, aussi bien en comparaison qu'en amélioration de cette algorithmique intuitive, reste donc vaste.

Références

Anonymous (2011) Open TURNS version 0.14.0 - Reference guide. Tech. rep., EDF - EADS - PhiMeca.

Bousquet, N. (2012) Accelerated Monte Carlo estimation of exceedance probabilities under monotonicity constraints. Special Issue on Mathematical Methods for Design and Analysis of Numerical Experiments. *Annales de la Faculté des Sciences de Toulouse (in press)* .

de Rocquigny, E. (2009) Structural reliability under monotony: A review of properties of FORM and associated simulation methods and a new class of monotonous reliability methods (MRM). *Structural Safety* **31**, 363–374.

Dutfoy, A. & Lebrun, R. (2009) A generalization of the nataf transformation to distributions with elliptical copula. *Probabilistic engineering mechanics* **24**, 172–178.

Garnier, J., Munoz Zuniga, M., Lefebvre, Y., Remy, E. & de Rocquigny, E. (2008) Estimation contrôlée de faibles probabilités sur des modèles physiques complexes - approfondissement aux modèles présentant des caractéristiques de monotonie. *Actes du congrès Lambda-Mu 2008* .

Hurtado, J. (2004) An examination of methods for approximating implicit limit state functions from the viewpoint of statistical learning theory. *Structural Safety* **26**, 271–293.

Kroese, D. & Rubinstein, R. (2007) *Simulation and the Monte Carlo Method (2nd edition)*. Wiley.

Li, L., Bect, J. & Vazquez, E. (1998) Bayesian subset simulation: a kriging-based subset simulation algorithm for the estimation of small probabilities of failure. *PSAM-ESREL 2012 Proceedings* **58**, 7–15.

Limbourg, P., de Rocquigny, E. & Andrianov, G. (2010) Accelerated uncertainty propagation in two-level probabilistic studies under monotony. *Reliability Engineering and System Safety* **95**, 998–1010.

Rajabalinejad, M., Meester, L., van Gelder, P. & Vrijling, J. (2011) Dynamic bounds coupled with Monte Carlo simulations. *Reliability Engineering and System Safety* **96**, 278–285.